

Relatório

de

Victor César Santos de Melo

Seu nome: Victor César Santos de Melo

Nome do professor: Glauco

Nome da matéria: Tópicos Avançados em Engenharia de Software e Sistema de Informação

09 de abril de 2026

Relatório Técnico: Avaliação de Desempenho de LLMs no Exame da OAB (Equipe 4)

1. Introdução e Contextualização

O presente relatório detalha a avaliação sistemática de modelos de linguagem de grande escala (LLMs) em cenários de alta complexidade jurídica, como parte integrante da disciplina "Tópicos Avançados 2026-1" (Equipe 4 – Domínio Jurídico). O objetivo técnico central foi mensurar a acurácia e a aderência semântica de quatro arquiteturas distintas frente às exigências do Exame da Ordem dos Advogados do Brasil (OAB), validando sua capacidade de interpretação normativa e raciocínio analítico no ordenamento jurídico brasileiro.

Os modelos submetidos ao benchmark foram:

- Gemini 2.5-Flash (Proprietário/API)
- Qwen 2.5-3B (Open Source/Execução Local)
- Llama-3-8B (Open Source/Execução Local)
- DeepSeek-R1-1.5B (Open Source/Execução Local)

2. Metodologia de Avaliação e Curadoria

A metodologia foi desenhada para replicar o rigor da correção analítica da Fundação Getúlio Vargas (FGV), garantindo a fidelidade técnica necessária para a automação de processos jurídicos.

- **Correção Analítica:** Adotou-se o critério de correção estruturada seguindo o *guideline single-oab-v1*. Esta abordagem desmembra as respostas em componentes semânticos e legislativos, avaliando não apenas a conclusão, mas o silogismo jurídico e a indicação correta de dispositivos legais.
- **Métrica Discursiva (BERTScore F1):** Em detrimento de métricas de sobreposição de tokens (como ROUGE ou BLEU), utilizou-se o **BERTScore F1** para as questões abertas. Esta métrica utiliza embeddings contextuais para capturar a essência das teses jurídicas, reconhecendo sinônimos técnicos e a profundidade analítica, o que é fundamental para validar conceitos como "pretensão punitiva" ou "erro de tipo permissivo" sem exigir literalidade absoluta do gabarito.
- **Curadoria de Dados:** O dataset trabalhado sob a supervisão do consultor Victor compreendeu os lotes de IDs 107 a 118 e 1108 a 1230. A amostragem abrangeu temas de alta densidade, incluindo **Direito Penal** (Teoria do Crime e Recursos), **Direito Tributário** (Conflitos de Competência de ISS) e **Direito Empresarial** (Recuperação Judicial - Lei 11.101/05).

3. Resultados Experimentais Consolidados

Os dados quantitativos revelam uma superioridade analítica dos modelos de maior escala para fundamentação, enquanto modelos locais menores apresentam eficácia surpreendente em tarefas objetivas.

Tabela 1: Modelos vs. BERTScore F1 (Questões Dissertativas)

Modelo	BERTScore F1
Gemini 2.5-Flash	0.6670
Qwen 2.5-3B	0.6144
Llama-3-8B	0.5281

Tabela 2: Modelos vs. Acurácia % (Questões Objetivas)

Modelo	Acurácia (%)
Qwen 2.5-3B	43.09%
DeepSeek-R1-1.5B	25.20%

4. Análise Qualitativa e Padrões de Erro

A análise crítica dos resultados aponta que os erros em questões objetivas concentraram-se majoritariamente em **Direito Processual**. Identificou-se que modelos de parâmetros reduzidos (3B e 8B) tendem a "alucinar" ou ignorar a lógica temporal de prazos e ritos. Um exemplo notório é a dificuldade em processar a **Apelação Supletiva (Art. 598 do CPP)**, onde o modelo deve calcular o decurso do prazo do Ministério Público para determinar a legitimidade do assistente de acusação — uma tarefa de lógica temporal que exige precisão técnica superior.

No campo do Direito Penal, a questão de ID 107 foi o principal teste de profundidade analítica:

"A avaliação do caso de Jonas exigia distinguir o 'erro de tipo permissivo' (Art. 20, §1º do CP) em relação a Frederico, do nexo de causalidade quanto à morte da criança. Enquanto a tese para a primeira vítima envolvia a legítima defesa putativa — com desclassificação para homicídio culposo se o erro fosse vencível —, o óbito da criança demandava a aplicação da teoria da causalidade adequada (Art. 13 do CP), tratando-se de causa independente que exclui o nexo causal do agente."

Além disso, observou-se que em questões de **Direito Tributário (ID 111)**, os modelos menores falharam ao analisar conflitos de competência de **ISS** em serviços de reciclagem (Art. 3º, VI da LC 116/2003), confundindo a regra geral do estabelecimento prestador com a exceção do local da execução. Em **Direito Empresarial (ID 116)**, a complexidade dos requisitos formais para a **Recuperação Judicial (Lei 11.101/05)** evidenciou que a falta de visão sistêmica dos modelos locais pode comprometer a instrução de petições iniciais complexas.

5. Conclusão Técnica e Recomendações

Com base na avaliação das métricas de NLP e na análise dogmática dos erros, este parecer técnico conclui:

1. **Superioridade Analítica:** O **Gemini 2.5-Flash** é o modelo mais indicado para a redação de peças e fundamentações doutrinárias complexas, apresentando a melhor captura de teses jurídicas de acordo com o BERTScore.
2. **Custo-Benefício Local:** O **Qwen 2.5-3B** consolidou-se como a "surpresa técnica", superando modelos maiores em acurácia objetiva, sendo a arquitetura ideal para automação de triagem em larga escala onde privacidade e baixo custo são prioritários.
3. **Indispensabilidade do BERTScore:** Reitera-se que métricas baseadas em embeddings contextuais são mandatórias no Direito, pois permitem validar o conhecimento jurídico em modelos que utilizam variações terminológicas corretas (ex: "descriminantes putativas" vs "legítima defesa putativa").
4. **Mitigação de Erros Processuais:** Para sanar as falhas em Direito Processual e prazos, recomenda-se a implementação de técnicas de **Chain-of-Thought (CoT)** para forçar o raciocínio passo a passo, ou o uso de **RAG (Retrieval-Augmented Generation)** alimentado com calendários processuais e o Código de Processo Civil/Penal.
5. **Parecer Final:** LLMs de parâmetros reduzidos são ferramentas poderosas de apoio, mas a supervisão técnica humana permanece indispensável para ritos procedimentais e teses que envolvam múltiplas camadas de causalidade normativa.