

Avaliação Orientada a Domínio e o Paradigma LLM-as-a-Judge

Glauco Carneiro - glauco.carneiro@dcomp.ufs.br

DComp/UFS, PROCC/UFS e PPGM/UFBA
Tópicos Avançados em ES e SI

09 de Abril de 2026

Recapitulação e Contexto

- ▶ **Aula 03:** Vimos como quantizar modelos para rodar no *Edge*.
- ▶ **Aula 04:** Vimos que ROUGE e BLEU falham em capturar semântica profunda.
- ▶ **Hoje (Aula 05):** Como construir benchmarks que realmente reflitam a perícia médica (Cardiologia) e jurídica (Direito Brasileiro).

O Declínio dos Benchmarks Generalistas

- ▶ Benchmarks como MMLU e GSM8K tornaram-se "saturados" ou contaminados.
- ▶ Modelos modernos decoram os dados de teste durante o pré-treinamento.
- ▶ *Referência*: "The Contamination Crisis in LLM Benchmarking" (*Nature Machine Intelligence*, 2025).
- ▶ **Consequência**: Precisamos de benchmarks privados, dinâmicos e focados em *Expertise* de Domínio.

Por que o Domínio Especializado é Diferente?

- ▶ **Vocabulário Específico:** Termos que mudam de sentido (ex: "competência" no Direito vs. uso comum).
- ▶ **Raciocínio Multietapa:** Uma resposta correta depende de uma cadeia de lógica (ex: diagnóstico diferencial em cardiologia).
- ▶ **Custo do Especialista:** Contratar médicos e juízes para validar 10.000 respostas de IA é financeiramente inviável.

O que é LLM-as-a-Judge?

- ▶ É o uso de um modelo de linguagem de alta capacidade (ex: GPT-5, Llama-4-400B) como um avaliador substituto do humano.
- ▶ O juiz não faz a tarefa; ele **critica** o resultado de outro modelo.
- ▶ *Vantagem*: Escalabilidade e custo reduzido.

Arquitetura do Fluxo de Avaliação

Para que a avaliação seja científica e auditável, o pipeline de julgamento deve seguir quatro pilares fundamentais:

1. **Input:** A pergunta original e a resposta gerada pelo modelo em teste.
2. **Referência:** O "Padrão-Ouro" e a régua de medição (Rubrica).
3. **Prompt do Juiz:** O protocolo de atuação do avaliador.
4. **Output:** O veredito estruturado contendo justificativa e nota.

Input: O Contexto do Problema

O Juiz não pode avaliar no vácuo. Ele precisa do cenário completo:

- ▶ **A Pergunta (Contexto):** Deve incluir o comando original (ex: "Analise o caso clínico abaixo" ou "Responda à questão da OAB").
- ▶ **Resposta do Aluno (Candidato):** É o *output* bruto gerado pelo modelo que vocês estão testando (ex: Llama-3 8B em 4-bit).
- ▶ **Importância:** Sem a pergunta, o Juiz não consegue detectar se o modelo "fugiu do tema", mesmo que o texto pareça bonito.

Referência: O Gabarito e a Régua

Aqui inserimos o conhecimento especializado do domínio:

- ▶ **Resposta Ouro (Gold Standard):** A resposta oficial do especialista humano. Essencial no dataset *K-QA* (Medicina).
- ▶ **Rubrica de Avaliação (A "Régua"):** Conjunto de regras que define o que é certo ou errado.
 - *Exemplo:* "Dê nota 1 se o modelo recomendar um medicamento contraindicado".
- ▶ **Conceito Chave:** A rubrica transforma um Juiz genérico em um perito especializado.

Prompt do Juiz: Programando o Avaliador

Este é o *meta-prompt* que define como o Juiz deve se comportar:

- ▶ **Persona:** "Você é um Desembargador" ou "Você é um Professor Titular de Cardiologia".
- ▶ **Protocolo de Julgamento:** Instruções sobre o que priorizar.
- ▶ **Proteções de Viés:** Instruir explicitamente o Juiz a:
 - Ignorar a verbosidade (tamanho do texto).
 - Penalizar severamente alucinações técnicas e inversões de sentido.

Output: O Veredito Estruturado

O resultado final deve ser objetivo e computável:

- ▶ **Raciocínio (Chain-of-Thought):** O Juiz deve explicar o "porquê" da nota antes de emití-la. Isso permite a auditoria humana do processo de correção.
- ▶ **Nota (Score):** Valor numérico (ex: 1 a 5) que permite gerar métricas de desempenho para a equipe.
- ▶ **Exemplo:** "O candidato acertou o diagnóstico, mas errou a dosagem da furosemida**. NOTA: 2".
- ▶ ** A **furosemida** é um potente diurético indicado para eliminar o excesso de líquidos e sais do corpo, sendo utilizada no tratamento de hipertensão arterial (pressão alta) e edemas (inchaço) causados por problemas no coração, fígado ou rins. Ela age aumentando a produção de urina.

Estado da Arte: Prometheus-3 (2025)

- ▶ *Artigo*: "From Generation to Judgment: Opportunities and Challenges of LLM-as-a-judge"(*Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, Nov 2025).
- ▶ <https://aclanthology.org/2025.emnlp-main.138/>
- ▶ Modelos treinados especificamente para serem juízes, evitando os vieses de modelos de chat.
- ▶ Introdução do conceito de **Rubricas Customizáveis**: O usuário define o que é "Correto" para o Direito Penal Brasileiro.

Cenário Prático: Direito Digital e LGPD

- ▶ **Tarefa:** Identificar cláusulas abusivas em contratos de Termos de Uso.
- ▶ **Problema:** O que é "abusivo" depende da jurisprudência atual do STJ.
- ▶ **Solução:** O LLM-Judge recebe o contrato e avalia a resposta do modelo base com base na legislação brasileira atualizada via RAG.

Cenário Prático: Laudos de ECG

- ▶ **Tarefa:** Gerar um sumário de um eletrocardiograma complexo.
- ▶ **Juiz Especialista:** Um modelo treinado em diretrizes da SBC (Sociedade Brasileira de Cardiologia).
- ▶ **Métrica de Segurança:** O Juiz deve penalizar com nota zero qualquer omissão de sinais de infarto agudo, mesmo que o texto esteja bem escrito.

O Viés de Verbosidade (Verbosity Bias)

- ▶ LLMs tendem a preferir respostas significativamente mais longas, confundindo extensão com qualidade.
- ▶ **Referência Real:** Zheng et al. (2023). *"Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena"*. Publicado no **NeurIPS**.
- ▶ **Evidência:** O estudo mostra que o GPT-4, ao atuar como juiz, exibe uma forte preferência por modelos mais "falantes", mesmo quando a precisão é idêntica.
- ▶ **Mitigação:** É necessário instruir o juiz a focar na "densidade de informação correta" e penalizar a prolixidade.

O Modelo Prometheus (Referência 2024/2025)

- ▶ Como alternativa aos modelos genéricos (GPT-4), surgiu o **Prometheus**.
- ▶ **Referência Real:** Kim et al. (2024). *"Prometheus: Inducing Fine-grained Evaluation Capabilities in Open Models"*. Publicado no **ICLR**.
- ▶ **Contribuição:** Um modelo de pesos abertos treinado especificamente para avaliação, superando o viés de verbosidade ao seguir rubricas rígidas.
- ▶ **Aplicação:** Ideal para o nosso cenário local (Edge Computing), onde precisamos de um juiz que rode em hardware próprio para auditar as equipes.

Viés de Auto-preferência (Self-Enhancement Bias)

- ▶ Modelos da família Llama tendem a dar notas maiores para outros modelos Llama.
- ▶ Isso distorce o benchmark e favorece ecossistemas específicos.
- ▶ **Solução:** Uso de **Ensemble Judging** (múltiplos juízes de famílias diferentes para um consenso).

Avaliação via Debate Multiagente (Multi-Agent Debate)

- ▶ Para reduzir vieses individuais, utiliza-se um processo de debate entre diferentes instâncias de LLMs.
- ▶ **Referência Real:** Chan et al. (2024). *"ChatEval: Towards Better LLM-based Evaluators through Multi-Agent Debate"*. Publicado no **ICLR**.
- ▶ **Como funciona:**
 - Vários agentes (ex: Juiz A, Juiz B, Juiz C) recebem a resposta do modelo.
 - Eles interagem entre si, criticando os pontos de vista dos outros avaliadores.
 - O veredito final surge do consenso após múltiplas rodadas de debate.
- ▶ **Resultado:** Supera significativamente o "Juiz Único" em correlação com a avaliação humana em tarefas complexas.

Construindo Rubricas de Avaliação

Uma boa rubrica deve ser:

1. **Explícita:** Definir o que é nota 1, 3 e 5.
2. **Hierárquica:** Priorizar precisão técnica sobre fluidez.
3. **Contextual:** Incluir "Se o modelo citar a lei X, considere correto".

Exemplo de Rubrica: Direito Penal

[Rubrica de Avaliacao]

Nota 1: Resposta juridicamente incorreta ou cita leis estrangeiras.

Nota 3: Resposta correta, mas nao cita o artigo especifico doCodigo Penal.

Nota 5: Resposta correta, fundamentada no CP/CPP e cita jurisprudencia recente do STF/STJ.

Exemplo de Rubrica: Cardiologia

[Evaluation Rubric]

Score 1: Dangerous recommendation or incorrect drug dosage.

Score 3: Correct diagnosis, but fails to mention follow-up tests (e.g., Echocardiogram).

Score 5: Accurate diagnosis, correct dosage, and aligns with AHA/ACC guidelines.

Validando o Juiz: Alinhamento e Meta-Avaliacao

- ▶ Como provar cientificamente que o seu "LLM-as-a-Judge" é confiável?
- ▶ **Referencia Real:** Liu et al. (2023). "*G-Eval: NLG Evaluation using Gpt-4 with Better Human Alignment*". Publicado no **Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing**.
- ▶ **Metodologia de Validacao:**
 - **Correlacao de Spearman / Pearson:** Mede o grau de concordancia entre as notas da IA e as notas de especialistas humanos.
 - **Resultado do G-Eval:** Demonstrou que o uso de *Chain-of-Thought* (explicabilidade) no Juiz eleva drasticamente a correlacao com humanos em tarefas de escrita e analise.
- ▶ **Meta-Avaliacao:** Não avaliamos apenas a resposta, mas a **capacidade avaliativa** do modelo juiz em relacao ao padrão-ouro humano.

Benchmarks Dinâmicos (Live Benchmarking)

- ▶ Benchmarks estáticos morrem no dia em que são publicados.
- ▶ **Tendência 2026:** Questões que mudam semanalmente baseadas em notícias reais e novos julgados.
- ▶ Isso impede que modelos "decorem" as respostas do benchmark.

- ▶ O Juiz também pode errar por falta de conhecimento atualizado.
- ▶ **Solução:** Fornecer ao Juiz ferramentas de busca (RAG) para consultar a lei ou o artigo médico antes de julgar o modelo.

Quem vigia os vigias?

- ▶ Auditoria de Juízes: Uso de modelos ainda maiores para avaliar a qualidade das justificativas dos juízes menores.
- ▶ **Justificativa Obrigatória:** Um juiz que dá nota sem explicar o porquê é considerado pouco confiável.

Aplicação: Projetos AURORA e Themis/ChatJT

- ▶ Como avaliar se o Robô Themis está sendo imparcial?
- ▶ Usamos um LLM-Judge configurado com rubricas de ética e imparcialidade para auditar as decisões automatizadas.

Ferramentas para Implementação

- ▶ **Giskard:** Focado em testes de estresse e detecção de viés.
- ▶ **DeepEval / Ragas:** Frameworks para testar pipelines de RAG usando LLM-as-a-Judge.
- ▶ **Prometheus-Eval:** Biblioteca Python para rodar os modelos Prometheus.

O impacto do Edge na Qualidade

- ▶ Modelos INT4 perdem capacidade de raciocínio complexo?
- ▶ O LLM-Judge é a ferramenta perfeita para detectar se a quantização "quebrou" o conhecimento jurídico do modelo.

- ▶ Delegar o julgamento à máquina remove a responsabilidade humana?
- ▶ O juiz-IA deve ser um suporte à decisão do professor/auditor, não o veredito final absoluto.

- ▶ Avaliar modelos em domínios críticos exige ir além de métricas de palavras.
- ▶ O paradigma LLM-as-a-Judge é o estado da arte para escala e profundidade.
- ▶ O segredo está na **Engenharia da Rubrica** e no combate aos vieses.